



MAX PLANCK INSTITUTE
FOR INFORMATICS



Utilizando Estratégias de Monitoramento Leve em Ambientes Containerizados para Detecção de Anomalias via HIDS

Anderson Frasão¹, Tiago Heinrich², Vinicius Fulber-Garcia¹, Newton C. Will³,
Rafael R. Obelheiro⁴, Carlos A. Maziero¹

¹Universidade Federal do Paraná - Curitiba, Brasil

²Instituto Max Planck de Informática - Saarbrücken, Alemanha

³Universidade Tecnológica Federal do Paraná - Dois Vizinhos, Brasil

⁴Universidade Estadual de Santa Catarina - Joinville, Brasil

Introdução

Fundamentação Teórica

Proposta

Avaliação Experimental

Conclusão

- ▶ Virtualização...
 - ▶ Surgiu como uma solução para os desafios de hardware dedicado;
 - ▶ Permite que uma única máquina física gerencie vários ambientes virtuais;
 - ▶ Oferece controle refinado sobre os recursos de computação, aumentando a flexibilidade, a mobilidade e a escalabilidade.

- ▶ Containerização...
 - ▶ Utiliza o kernel do sistema operacional para criar ambientes isolados para processos específicos;
 - ▶ Conhecido pelo baixo consumo de recursos e pela sobrecarga mínima de processamento;
 - ▶ A popularidade gera preocupações de segurança devido ao menor isolamento em comparação com a virtualização baseada em hipervisor.


- ▶ Preocupações de segurança com contêineres:
 - ▶ Aumento dos vetores de ataque, incluindo escalonamento de privilégios, ataques de canal lateral e negação de serviço:
 - ▶ CVE-2017-5123
 - ▶ CVE-2018-10846
 - ▶ CVE-2018-12122
 - ▶ Requer sistemas robustos de detecção de intrusão (IDS) para monitorar e proteger ambientes de contêineres.
- ▶ As ferramentas de IDS existentes, como o *strace*, impõem uma sobrecarga de desempenho significativa;
- ▶ Necessidade de coleta de dados eficiente e em tempo real e detecção de anomalias em ambientes de contêineres.

- ▶ Utiliza o *kernel* de um sistema para isolar processos;
- ▶ Permite inicializações rápidas, em milissegundos, e maior eficiência em comparação às máquinas virtuais convencionais.
- ▶ Não necessitam incluir uma cadeia completa de ferramentas para executar um sistema operacional;
- ▶ Eliminação da emulação de *hardware* e da inicialização de um sistema operacional completo.


- ▶ Definição de anomalia:
 - ▶ Desvio do comportamento esperado dos dados;
 - ▶ Causas:
 - ▶ Atividade maliciosa;
 - ▶ Mau funcionamento do software/hardware;
 - ▶ Configurações incorretas, etc.
- ▶ Detecção de anomalias:
 - ▶ Identificação de padrões inesperados;
 - ▶ Envolve sistemas de detecção de intrusão que coletam eventos;
 - ▶ Avaliação de novos dados em relação ao modelo para identificar desvios.

- ▶ Interface que um sistema operacional oferece às aplicações;
- ▶ Acesso a funcionalidades do sistema;
- ▶ Ponto privilegiado de observação e controle do comportamento de aplicações do ponto de vista de segurança;
- ▶ Ataque tem um ponto em comum: Uso da interface de chamadas de sistema;
- ▶ Monitoramento de chamadas do sistema é amplamente empregada para detectar aplicações comprometidas;
 - ▶ Compara a captura com comportamento normal previamente salvo, interrompendo a execução se desvios forem detectados.

- **Avaliação:** Aplicação em contêineres para detecção de anomalias usando aprendizado de máquina;
- **Objetivo:** Investigar o uso de chamadas de sistema para detecção de anomalias e a viabilidade de HIDS baseados em aprendizado de máquina.



- ▶ A ferramenta *Sysdig* foi utilizada para a coleta de dados (*syscalls*);
- ▶ Utiliza um driver chamado *sysdig-probe* para capturar eventos no kernel via *tracepoints*;
- ▶ *Tracepoints* permitem instalação de *handlers* em funções específicas do kernel, copiando detalhes do evento para um buffer compartilhado;
- ▶ *libscap* e *libsinsp* ajudam na leitura, decodificação e análise dos eventos capturados.



- ▶ Uso do sysdig para capturar chamadas de sistema e atividades em um contêiner Docker;
- ▶ Estrutura de coleta: Identificador de evento, *timestamp*, *thread*, nome/ID do contêiner e processo, *system call* com parâmetros;
- ▶ Extração de características relevantes e redução de ruído nos dados coletados;
- ▶ 10 execuções por amostra (benigna/maliciosa) para garantir diversidade no conjunto de dados.

- ▶ Uso de grid search para determinar os melhores parâmetros para modelos de aprendizado de máquina;
- ▶ Possível implementação de HIDS para identificar anomalias e intrusões em tempo real;
- ▶ Detecção desvios significativos dos padrões estabelecidos, identificando possíveis ameaças.

- ▶ Ambiente de Teste:
 - ▶ Linux 5.15.0-56-generic 62-Ubuntu;
 - ▶ Linux Mint 21.2;
 - ▶ Docker 20.10.21.
- ▶ Algoritmos Selecionados
 - ▶ Random Forest (RF);
 - ▶ XGBoost (XGB);
 - ▶ Decision Tree (DT);
 - ▶ Nu-Support Vector (NuSV);
 - ▶ Multi-layer Perceptron (MLP);
 - ▶ AdaBoost (AB);
 - ▶ Stochastic Gradient Descent (SGD).
- ▶ Com esses algoritmos, pudemos avaliar o uso de aprendizado de máquina para a detecção de anomalias.

- ▶ Aplicação utilizada: *Wordpress*, versão 4.9.2;
- ▶ Conjunto de dados composto por 200 arquivos com sequências de chamadas de sistema;
- ▶ Vulnerabilidades exploradas:
 - ▶ Injeção de código arbitrário (Social Warfare);
 - ▶ Upload e execução de código PHP arbitrário (Gerenciador de arquivos);
 - ▶ Falha na validação de extensões de arquivos, permitindo que arquivos PHP sejam carregados e executados (Simple File List);
 - ▶ Injeção de SQL (LeagueManager);
 - ▶ Download de arquivo remoto (Paypal Currency Converter Basic For WooCommerce).

- ▶ *Grid Search* utilizado com o pacote scikit-learn.
- ▶ Identificado os melhores parâmetros para maximizar a eficácia dos modelos.
- ▶ Configuração dos Experimentos:
 - ▶ Técnica Utilizada: *k-fold* de 5
 - ▶ Conjunto de dados dividido em 5 partes iguais para treinamento e teste.
- ▶ Métricas de Desempenho Consideradas:
 - ▶ ROC (*Receiver Operating Characteristic*);
 - ▶ *Precision* (Precisão);
 - ▶ *Recall*;
 - ▶ *f1-Score*;
 - ▶ *Accuracy* (Acurácia);
 - ▶ *Balanced Accuracy* (BAC);
 - ▶ *Brier Score* (BS).

- ▶ Modelo de Destaque: AdaBoost;
- ▶ Precisão: 93,48%;
- ▶ *Recall*: 87,76%;
- ▶ ROC: 97,68%;
- ▶ BS: 9%;
- ▶ Analise:
 - ▶ Alta precisão: baixa taxa de falsos positivos;
 - ▶ Alta capacidade de discriminação e calibração;
 - ▶ Sólida taxa de recall: reduz falsos negativos.

- ▶ Modelos com desempenho médio:
 - ▶ *Random Forest, Nu-Support Vector, Multilayer Perceptron, XGBoost;*
- ▶ Taxas de precisão e recall acima de 77%;
- ▶ ROC, BAC, e BS na média;
- ▶ Considerações:
 - ▶ Balanceamento entre falsos positivos e falsos negativos.
 - ▶ Adequados para diversas aplicações, dependendo do contexto.

- ▶ **Uso de Grid Search:**
 - ▶ Identificação de parâmetros adequados para detecção de anomalias;
 - ▶ Viabilidade do uso de modelos de aprendizado de máquina para soluções HIDS.
- ▶ **Efetividade do Sysdig:**
 - ▶ Confirmação do uso de chamadas de sistema coletadas para detecção de anomalias;
 - ▶ Desenvolvimento de HIDS mais eficientes e menos intrusivos.
- ▶ **Conclusão Principal:**
 - ▶ **O uso de dados de monitoramento do sysdig permite a criação de modelos eficazes de aprendizado de máquina, melhorando a segurança em ambientes virtualizados.**

- ▶ Adoção de Contêineres...
 - ▶ Permite o compartilhamento eficiente de um sistema operacional entre múltiplas instâncias de aplicativos;
 - ▶ Benefícios: Portabilidade, economia de memória, facilidade de migração;
 - ▶ Riscos: Implementação inadequada e vulnerabilidades.
- ▶ Monitoramento e Detecção de Intrusões
 - ▶ Uso de HIDS e monitoramento leve para detectar anomalias em contêineres;
 - ▶ Possibilidade do uso de dados de monitoramento provenientes do *sysdig*;
 - ▶ Modelos de aprendizado de máquina utilizados para análise de dados coletados.

► Resultados do Modelo AdaBoost:

- Precisão: 93,48%;
- *Recall*: 87,76%;
- ROC: 97,68%;
- *Brier Score*: 9%;
- Conclusão: Monitoramento leve é eficaz para HIDS.

► Trabalhos Futuros:

- Testar soluções de monitoramento leve adicionais (eBPF, Ftrace, LTTng);
- Comparar eficácia e adequação dos dados para modelos de aprendizagem de máquina;
- Desenvolver soluções de HIDS mais abrangentes com um conjunto de dados maior e rotulado.

SECRET



MAX PLANCK INSTITUTE
FOR INFORMATICS



Obrigado!

Contato: aacf20@inf.ufpr.br